
ESM Cambrian × fungi-cazyme-PLM

项目集成报告

Evidence review, task mapping, architecture, evaluation, risk, compute budget, and reproducible execution on met.unl.edu

PROJECT	dbCAN-SF / fungi-cazyme-PLM
VERSION	1.0 - 2026-07-21
STATUS	Design complete; model training not authorized
PRIMARY DECISION	ESMC 600M sequence-first; 6B SAE as B8; structure selective

Primary evidence: Candido et al. 2026 preprint; Biohub official tutorials and current release; promoted fungi-cazyme-PLM Phase 0 artifacts.

项目名称：dbCAN-SF (fungal structure-aware CAZyme annotation and function decoding) 报告版本：1.0 日期：2026-07-21 状态：设计与证据审阅完成；模型训练尚未授权 目标读者：项目负责人、CAZyme/真菌生物信息学研究者、模型与数据工程人员

本报告回答一个具体问题：ESM Cambrian (ESMC) 应当在 dbCAN-SF 中承担什么角色，怎样验证它确实比现有序列、结构和检索方法增加了可发表的生物学价值，以及在什么条件下应停止扩展。报告不把通用酶学结果外推为 CAZyme 结果，也不把模型解释当成实验注释。

1. 执行摘要

1.1 核心结论

- ESMC 值得进入项目，但不能绕过 Phase 0。当前仓库已经证明 fungal CAZyme family-instance 的 preliminary addressable gap 为 32.84%，高于预注册的 5% 阈值；同时还有 36 个不同序列的 canonical ID 冲突、独立边界金标准缺失、蛋白级功能标签缺失、2024 seed identity 未完成和 GPU ceiling probe 未完成。ESMC 只能提高表征能力，不能修复标签真实性、标识符冲突或数据泄漏。
- 主路线应是 sequence-first, structure-selective。当前 CAZyme3D exact + 90/80 near-match 覆盖率仅为 29,671/524,926 (5.6524%)。因此 ESMC 600M 应首先作为 frozen sequence encoder；结构预测和 SaProt 融合集中在 <30% identity、fam-0、难例和高价值候选，而不是全库先折叠。
- 不能为所有任务指定同一层。论文和教程都显示功能、结构和稳定性信号在不同深度达到峰值。T1、T2、T3 必须分别进行 layer sweep；最终层只作为对照，不是默认最优层。
- ESMC 6B SAE 是最有价值的新基线。论文中的 layer-60、Top-K 64、16,384-codebook SAE 在低序列一致性检索上优于 dense ESMC、MMseqs2 和 Foldseek。它应被加入 B8，用于远缘家族、clan 和 fam-0 检索；自动生成的 feature description 只用于提出假设。
- ESMFold2 只做定向补充。它可提供 pLDDT、PAE、可选 MSA 和复合物推理，但不应替代项目已有的 PDB/CAZyme3D/AFDB 层级，也不应在 Phase 0 阶段进行全库预测。
- 2026 发布修正了旧许可判断，但尚未自动解除项目许可门槛。Biohub 当前模型页和官方仓库将当前 ESMC、ESMC SAE 和 ESMFold2 发布标为 MIT，并开放 Hugging Face 权重；legacy *-2024-12 产物仍必须按其自己的模型卡和历史条款审计。正式实验前必须固定精确 model_id、revision、权重哈希和许可证快照。
- 本项目不是“第一个 CAZyme PLM”。CAZyLingua 和 CAALM 已覆盖 sequence-only family annotation。项目的可发表贡献应是 fungal domain-level resolution、结构增量的可证伪位置、跨家族 function decoding 和 retrospective fam-0 discovery。

1.2 建议的模型分工

组件	项目角色	是否全库运行	晋级条件
ESMC 300M	数据流、显存和吞吐 smoke test	否	产物 schema、长序列和哈希验证通过
ESMC 600M frozen	T1-T3 主要 sequence encoder ；逐任务选层	是，选层后	在相同 split/head 下超过或达到 ESM-2 的性能-成本 Pareto 前沿
ESMC 600M LoRA	frozen ceiling 后的有限适配	否，先 pilot	frozen 结果稳定且 hard-label gate 满足
ESMC 6B dense	上界与远缘小规模 benchmark	否	仅在预注册子集评估，记录多 GPU 成本
ESMC 6B SAE	B8 远缘检索、fam-0、解释	否，先 domain pilot	<30% identity / whole-clan 检索优于现有基线
SaProt/Foldseek	结构表示与诚实结构基线	结构可用子集	对 clan/remote/fam-0 有配对置信区间增益
ESMFold2	缺失结构的定向补全	否	只进入高价值候选，保留 pLDDT/PAE

2. 项目现状与不可绕过的约束

本报告以仓库 promoted Phase 0 结果为数值事实来源，不重新解释或手工重算这些数字。

项目事实	当前结果	对 ESMC 集成的约束
fungal truth family instances	728,439	需要 domain/family 层评估，而不只是 protein binary
preliminary addressable instances	239,217 (32.84%)	支持继续探索，但不是最终 go decision
normalized comparison rows	1,980,140	全库嵌入前必须先做吞吐与存储预算
weak HMM domains	536,133	可训练 T1，但不能作为独立 boundary test
function mapping	1,024 physical / 1,023 unique ; 390 families	只能定义 vocabulary/weak labels
polyspecific families	88	强制保留多标签和 family lookup baseline
local structure coverage	5.6524%	采用 sequence-first、按价值预测结构
alias conflicts	36	归零前不得建立正式 embedding/protein join
unresolved-genome records	68,811	taxonomy 未解决前不得进入 order holdout
official ESM-2 ceiling	缺失	ESMC 不能替代该连续性基线

2.1 Phase 0 的六个模型前置门槛

- **protein_alias_integrity** : 36 个 canonical conflict 必须显式裁决或 namespace ；禁止按 first/last row 静默覆盖。
- **seed_identity_2024** : 完成 214,618 planned queries ，并标明 reference release 是 2024 MSA。
- **ceiling_probe** : 恢复 GPU 后完成 ESM-2 650M frozen cluster30 基线。
- **protein_level_function_labels** : 获得 characterized protein-level substrate/EC 数据。
- **independent_boundary_gold** : 获得 curated/PDB/独立结构解析边界 ；HMM envelope 只作 weak supervision。
- **licence_release_decision** : 为将实际使用的 current/legacy encoder 固定模型卡、revision、哈希与许可证。

在这些门槛未全部满足时，可以运行 schema smoke test、吞吐 benchmark 和 weak-label feasibility；不得发表“边界优于 dbCAN”“跨家族功能泛化”或“fam-0 发现性能”的 headline claim。

3. ESMC 论文：哪些证据可用，哪些不能外推

论文为 2026-06-04 发布的 bioRxiv preprint，尚未经过同行评审。以下页码指用户提供的 111 页 PDF。

3.1 规模、训练语料与上下文

- ESMC 发布 300M、600M、6B 三个规模。Table S1 (PDF p29) 给出 30/36/80 层，隐藏维度 960/1152/2560，attention heads 15/18/40。
- 训练语料合计 2.806 billion sequences：UniRef2023_02156M、JGI2.029B、MGnify2023_02621M (PDF p3)。这意味着 CAZy 蛋白很可能在无标签预训练中出现，temporal split 不能自动消除 PLM contamination。
- Stage 1 使用 512-token context 训练 1M steps；Stage 2 使用 2,048-token context 继续 500K steps (PDF p28-p29)。对 fungal multi-domain proteins 不能复制教程的固定 1,024 截断。
- ESMC 6B 的功能 kNN probe 在 layer 50-60 附近达到峰值，而 long-range contact 在后层、接近 penultimate layer 达峰 (PDF p4)。因此“最后层统一用于所有任务”缺乏依据。

3.2 EC-CATH：支持远缘功能方向，但不是 CAZyme benchmark

EC-CATH 数据只保留长度 ≤ 512 、单一完整 EC、单一完整 CATH domain 的蛋白。最终包含 5,829 个 unique positive proteins、9,211 个 structure-matched negatives、73 个 leave-one-CATH-out tasks，覆盖 32 个 EC numbers 和 42 个 CATH topologies (PDF p30-p31)。6B 在 53/73 tasks 上排名第一 (PDF p33)。

对本项目的正确解读是：

- ESMC latent space 可能含有跨 fold 保留的功能方向，支持 T3 whole-clan / whole-family pilot。
- 该数据刻意排除了多结构域、长蛋白和不完整标签，而这些正是 fungal CAZyme 的主要困难。
- 每个 task 选择最佳层和模型，并在 held-out topology 上调正则/选 seed；它的目标是发现表征方向，不是给出可直接部署的 EC classifier。
- 因此不能把“53/73 tasks”写成 ESMC 对 CAZyme 或真菌功能预测的胜率。

3.3 Stability：证明表征可被线性读取，不是本项目主任务

论文在 Megascale stability 数据上使用 mean-pooled penultimate-layer embeddings 和 ridge regression。ESMC 6B 对跨结构家族 global ΔG 的最佳 Spearman 约 0.68；在 25% identity-filtered FireProt 上，学习到的 stability direction 对 37 个 landscapes 的平均相关接近 0.5，而 pseudoperplexity 约 0.2 (PDF p34)。

这支持“先 frozen probe，再决定 LoRA”的工程顺序，但 stability/ ΔG 不属于 dbCAN-SF 的四个核心任务。Mutation scoring 只能作为未来 protein engineering extension，不能挤占 T1-T4 的数据与计算预算。

3.4 SAE：对 fam-0 最直接的新机会

论文分析的主 SAE 使用 ESMC 6B layer 60、Top-K 64、16,384-dimensional codebook (PDF p12、p73-p74)。它将每个 residue 的 dense representation 分解成 sparse features，再对 domain/protein 做 max pooling。

关键结果：

- 在 14,841 个至少有 10 个样本的 Pfam families 中，超过 88% 的 family median within-family Jaccard >0.6 ；100,000 个跨 family 随机对的 median 只有 0.177 (PDF p95) 。
- CATH S95 和 SwissProt full-EC 检索显示，在 <40% sequence identity 区间，SAE similarity 优于 mean-pooled ESMC、MMseqs2 和 Foldseek (PDF p95-p96) 。
- 对 <30% identity 的 CATH true-homolog pairs，SAE cosine 的 near-perfect retrieval 约 70%，dense ESMC 约 64%，Foldseek 约 65% (PDF p96) 。

这些结果直接支持新增 B8，但仍有三项限制：数据不是 CAZyme；CATH/EC benchmark 与 fungal taxonomy 分布不同；agent-generated descriptions 是数据库驱动的自动假设，不能写入 gold label。

4. 官方教程到项目实现的转换

教程	官方示例	本项目采用	本项目不照搬
Embedding	API batch executor；all-layer mean hidden states；ADK layer 12 比 layer 30 更好	分任务 layer sweep；保存 layer/pooling/revision	盲选最后层；只做全蛋白 mean pooling
Layer sweep	593 SwissProt enzymes、4 个 EC3 classes、600M 37 states、5-fold stratified CV、MCC	同一 probe 跨 layer 比较；MCC 保留为不平衡指标	随机 CV 作为主结果；在 test fold 上选择模型
LoRA	biohub/ESMC-300M、CLS pooling、rank 8、alpha 16、dropout 0.01、1,024 truncation	rank/alpha/target modules 作为初始值；T1 改 token head，T2/T3 改 domain pooling	直接采用 CLS 和 1,024 截断；1,000-step demo 当正式训练
Mutation	leave-one-out mask、entropy、single-AA LLR	未来候选位点的 compatibility 证据	把 LLR 当稳定性、活性或实验真值
SAE	6B layer60 k64 codebook16384、TF-IDF、max activation/prevalence、3D mapping	B8 domain retrieval；激活位置辅助解释	固定 feature ID 语义；忽略 sequence-structure alignment
ESMFold2	esmfold2-fast-2026-05、loops/sampling、optional MSA、pLDDT/PAE	定向缺失结构补全；保存 confidence/config	全库折叠；用低 pLDDT 结构作为确定证据

4.1 教程中的 LoRA 初始参数

教程把 out_proj 作为 target_modules，把 layernorm_qkv.weight、ffn.fc1_weight、ffn.fc2_weight 作为 target_parameters，并保存 classifier。项目初始配置采用 rank=8、alpha=16、dropout=0.01。这些是复现实验起点，不是已优化超参数；任何调整只能用训练折和 validation fold，不能读取 test fold。

4.2 教程中的评估泄漏风险

Layer sweep 教程明确说明其结果主要用于比较层而不是 rigorous benchmark。本项目必须把层选择嵌套在 training/validation 内：外层 cluster30/order/temporal/family split 用于最终测试，内层只在训练数据中选择 layer、pooling 和 probe。随机 stratified CV 仅作为 tutorial reproduction 与 leakage sensitivity control。

5. T1-T4 的具体集成设计

5.1 T1 - residue-level CAZyme class 与边界

输入：full protein sequence；可选 structure token 与 residue-level pLDDT。sequence branch：ESMC 600M 每层 residue hidden states。输出：每残基 {non-CAZyme, GH, GT, PL, CE, AA, CBM} 概率、boundary probability、连续 domain segments。

实施顺序：

1. 用 300M 在 fixture 和少量真实序列上验证 token/coordinate 对齐。
2. 600M layer sweep 只在 boundary-training subset 上运行；每层使用完全相同的 token head。
3. HMM envelopes 作为 weak training labels；curated/PDB/independent structure parse 只作 hard evaluation。
4. 后处理需要合并短 gap、移除低于 minimum length 的孤立段，并在 validation set 上冻结阈值。
5. 只有 frozen head 稳定后才启用 LoRA；LoRA 不改变 test split 或 boundary gold。

主指标：residue macro-F1、domain precision/recall at IoU 0.5/0.75、segment IoU、boundary F1 at $\pm 5/10/20$ aa、protein AUPRC。HMM-envelope test 只能报告 agreement，不得称为 independent accuracy。

5.2 T2 - domain family、clan 与 open-set

T2 不对整条多结构域蛋白做平均。对 T1 segment 或 gold/weak domain 坐标内的 token states 分别计算 mean、max、attention pooling，并在 validation fold 选择 pooling。

输出采用层级形式：

```
CAZyme class -> clan -> family/subfamily
-> unknown/open-set score
-> nearest dense/SAE/sequence/structure neighbors
```

- abundant families 使用 calibrated classifier。
- rare/zero-shot families 使用 retrieval 与 prototype 路线。
- clan auxiliary head 是 Claim 1 的直接检验对象。
- unknown score 同时比较 energy、Mahalanobis、prototype distance、conformal score 和 neighbor consistency；选择只能在 retrospective benchmark 完成。

5.3 T3 - function decoder

每个 domain 输出结构化多标签，而不是自然语言自由生成：

```
substrate polymer
linkage / anomeric specificity
EC level 1-4 ( 允许 partial )
mechanism ( retaining / inverting / unknown )
mode ( endo / exo / processive / unknown )
```

训练标签分级：protein-level characterized > subfamily > family；后两者只作 weak supervision。

characterized-only 与 whole-family holdout 是主评估，family-to-substrate lookup B6 必须与每个 headline number 同表出现。若 decoder 在 held-out families 和 characterized-only set 上不能超过 B6，Claim 2 判定失败。

SAE 可提供两个补充输入：domain max-pooled sparse vector，以及与候选功能 prototype 共享的 feature set。SAE description 不参与构造真值，不把自动描述反向写进 substrate/EC 标签。

5.4 T4 - fam-0 retrospective benchmark

用 CAZy release N 的 fam-0 作为 query，仅使用 release N 可得的训练数据；在 N+k 查询后续状态：仍未分配、进入已有 family、形成新 family。对每个 query 保存完整排序而非只保存命中。

比较：ESMC dense、ESMC SAE、MMseqs2、Foldseek、SaProt、CAALM。报告 Recall@k、MAP、nDCG、first-correct rank、assignment AUROC/AUPRC，以及新 family 的 pre-resolution clustering consistency。fam-0 永远不是 negative class。

6. 长序列、结构融合与产物设计

6.1 长序列策略

- 实际 residue budget 从 tokenizer/model config 读取：`max_position_embeddings - special_tokens`，不硬编码 2,048 residues。
- 不超过 budget 的蛋白整条编码；更长蛋白使用 256-aa overlap。
- T1 的重叠 token logits 使用中心权重融合；edge residue 的权重不得为 0。
- T2/T3 优先用完整 domain + 64-aa flank；若 domain 本身超过 budget，按相同窗口策略切分并在 domain 内汇总。
- 每条预测必须记录 window start/end、overlap、merge method 和是否覆盖完整 domain。
- 全库不保存所有层的 residue embeddings。layer sweep 子集可保存 all-layer pooled states；选层后全库保存 domain pooled embedding、最终 token logits 和必要的 selected-layer states。

6.2 pLDDT-aware structure fusion

结构来源优先级保持为 PDB -> CAZyme3D -> AFDB $\geq 90\%$ identity / $\geq 80\%$ coverage -> high-value prediction。fusion gate 输入 sequence state、structure state、per-residue pLDDT、structure source 和 missing mask。

必须报告三组：experimental/curated structure、predicted structure、no structure。结构被 mask 时模型性能不得显著低于独立 sequence-only 模型；否则不满足 graceful degradation，不能作为 run_dbCAN 可部署路线。

6.3 模型产物数据契约

新增 `schemas/model_artifact_manifest.schema.json`，核心字段包括：

- 身份：`artifact_id`、`run_id`、`task`、`artifact_uri`；
- 模型：`model_id`、`model_revision`、`code_revision`、`weights_sha256`、license snapshot；
- 表征：`layer_indices`、`pooling`、`embedding_dim`、`dtype`、SAE 名称/codebook；
- 生物对象：`canonical_id`、`sequence_sha256`、可选 `domain_index` 与 1-based inclusive coordinates；
- 上下文：最大 residue budget、overlap、window/merge policy；
- 结构：source、predictor revision、mean pLDDT threshold；
- 实验：split ID、seed、hardware、peak VRAM、GPU-hours、cache hit rate。

三类下游表分别为 residue predictions、domain predictions、retrieval results。它们通过 `canonical_id + sequence_sha256`，以及 domain 表的 `domain_index` 关联，不覆盖 `domains.parquet` 中的 weak/gold labels。

7. Split、污染与公平比较

7.1 主 split 层级

- 1. cluster30：主要远缘结果；同时报告 cluster40/50 sensitivity。
- 2. fungal order holdout：只使用 taxonomy 已解析记录。
- 3. temporal holdout：所有 baseline 降级或重建到相同 release N。
- 4. whole-family holdout：T3 的决定性测试。
- 5. whole-clan holdout：最强 extrapolation 和 Claim 1 测试。

每个 split 输出 leakage report：train-test maximum identity、shared sequence hashes/IDs/genomes/taxa/clusters、database version overlap、held-out family/clan 验证、PLM pretraining-contamination strata。

7.2 PLM contamination

ESMC 预训练包含截至 2023 的大规模 UniRef/JGI/MGnify；测试蛋白即使在 2025 才获得 CAZy 标签，也可能早已作为无标签序列进入 PLM。报告必须区分：

- label-time generalization：预训练可能见过序列，但没见过 CAZy 标签；
- sequence-time generalization：近似 PLM-unseen，按 UniProt first-seen/corpus cutoff 分层；
- family/clan generalization：训练监督数据中无该 family/clan。

不得用“temporal split”单独声称模型从未见过测试序列。

8. Baseline 与模型实验矩阵

8.1 Baseline

ID	方法	主要作用
B0	run_dbCAN V5	T1-T3 primary comparator
B1	DIAMOND/MMseqs2 label transfer	sequence homology floor
B2	Foldseek vs CAZyme3D	honest structure baseline
B3	CAZyLingua	published PLM comparator
B4	CAALM	hierarchical/retrieval PLM comparator
B5	dbCAN-sub	T3 substrate/EC comparator
B6	dbCAN family -> substrate lookup	Claim 2 deciding baseline
B7	composition/k-mer + gradient boosting	sanity floor
B8	ESMC 6B SAE domain retrieval	remote/open-set/interpretable baseline

8.2 模型阶段

ID	模型	结构	目的
M0	ESM-2 650M frozen	no	continuity ceiling
M1a	ESMC 300M frozen	no	smoke/cost floor
M1	ESMC 600M frozen layer sweep	no	sequence representation ceiling
M2	ESMC 600M LoRA	no	T1/T2/T3 adaptation
M3/M4	SaProt frozen/LoRA	yes	structure PLM
M5	ESMC + SaProt pLDDT-gated fusion	optional	Claim 1
M6	M5 + function decoder	optional	Claim 2
M7	optional fungal adapter DAPT	optional	kill-criterion extension

B8 不是 M6 的替代品：B8 检验 sparse representation 是否适合检索；M6 检验结构化功能属性能否跨 family 解码。

9. 评估、统计与晋级规则

任务	主指标	关键分层
T1	residue macro-F1 ; segment IoU ; boundary F1 ±5/10/20 ; protein AUPRC	boundary evidence、length、single/multi-domain
T2	macro-MCC/F1 ; top-1/3/5 ; hierarchical error ; OOD AUROC/AUPRC/FPR95	identity、clan、family size、taxon
T3	macro-AUPRC ; multi-label F1 ; tuple exact/partial ; Brier/ECE	label level、whole-family/clan、polyspecificity
T4	Recall@k ; MAP ; nDCG ; first-correct rank ; future-assignment AUROC	later family type、identity、structure availability

- 使用 paired bootstrap 95% CI；比较模型时测试蛋白完全相同。
- 运行 3-5 个独立 cluster partitions；便宜时再报告初始化 seed variance。
- layer、pooling、threshold、LoRA 超参数都在 nested validation 内冻结。
- Structure branch 只有在 <30% identity / clan / fam-0 的预注册主指标下界高于 sequence-only 才晋级。
- ESMC 600M 只有在性能优于 ESM-2，或同等性能下显著降低成本/提高可部署性时晋级默认 encoder。
- Function decoder 未超过 B6，或 SAE 未超过 B1/B2/B4 时，按负结果报告并停止相应扩展。

10. met 服务器执行与可复现性

权威计算目录为：

met.unl.edu:/array1/xinpeng/fungi-cazyme-PLM

2026-07-21 只读检查显示：8 × NVIDIA RTX A5500 (每张约 24 GB)、约 2.0 TB /array1 可用空间、uv、Python 3.11/3.12 和 tmux 可用，未检测到 Slurm/PBS。服务器 system Python 3.10 不满足项目 >=3.11，必须通过 uv 建立 .venv。

10.1 推荐环境

```
ssh met.unl.edu
cd /array1/xinpeng/fungi-cazyme-PLM
git pull --ff-only
uv venv --python 3.11 .venv
uv pip install --python .venv/bin/python -e '[dev]'
.venv/bin/python -m pytest
```

10.2 长任务

使用 `scripts/remote/met_run.sh`，它默认拒绝 dirty Git tree，并为命令创建不可变 `logs/remote_runs/<run_id>/`，记录 `command`、`commit`、`host`、`GPU`、`环境`、`stdout/stderr` 和最终状态。

```
tmux new -s fcplm-esmc
cd /array1/xinpeng/fungi-cazyme-PLM
./scripts/remote/met_run.sh --name phase0-smoke --gpu 0 -- \
.venv/bin/python -m fungi_cazyme_plm.cli smoke \
--config tests/fixtures/config.yaml
```

离开 tmux 使用 `Ctrl-b d`；恢复使用 `tmux attach -t fcplm-esmc`。不要用 `nohup ... &` 代替 manifest wrapper，因为它通常丢失提交、参数和结束状态。

Cursor 已通过 Remote-SSH 连接时，确认左下角显示远端 `met`，打开该目录并运行 `Codex: Open Codex Sidebar`。Codex IDE 官方支持 Cursor-compatible editors；IDE 会使用当前编辑器所打开的远端工作区。Codex CLI 是另一条独立路径；当前服务器 PATH 未检测到 `codex`，但不影响已安装的 Cursor extension。

详细步骤见 `docs/remote_execution_met.md`。

11. 计算与存储 stop-loss budget

所有预算先由 1,000 和 10,000 protein benchmark 实测 `tokens/s`、`peak VRAM` 和 `bytes/domain`，再外推；严禁直接启动 524,926 proteins 的 all-layer residue extraction。

阶段	硬上限	超限处理
300M schema/smoke	4 GPU-hours	修复数据流，不扩大样本
600M 10k throughput + layer pilot	32 GPU-hours	缩短候选层/只保留 pooled states
600M selected-layer full extraction	256 GPU-hours ; 500 GB	改 on-the-fly head 或分片压缩
LoRA pilot	24 GPU-hours/config ; 最多 5 configs	未超过 frozen 则停止
6B dense + SAE pilot	128 GPU-hours ; 200 GB	只保留 sparse domain summaries
targeted ESMFold2	10,000 sequences 或 256 GPU-hours	按不确定性与价值进一步筛选

在新的人工批准前，总 stop-loss 为 800 GPU-hours。估算公式：

```
GPU-hours = total_tokens / measured_tokens_per_second / 3600 * GPU_count
storage = rows * dimensions * bytes_per_value + index/metadata overhead
```

全库只保存 selected-layer domain pooled embeddings 和最终预测；all-layer token states 只保存在 layer-selection 子集。所有缓存以 `sequence_sha256 + model_revision + layer + window_policy` 为键，避免重复付费。

12. 风险登记与停止条件

风险	后果	控制/停止条件
论文是 preprint 且无 fungal CAZyme benchmark	外推过度	所有结论必须在项目 split 重测
CAZy/dbCAN 标签共同由 similarity 驱动	假性“超越”	low-identity、temporal、characterized-only
HMM boundary circularity	T1 虚高	hard boundary set 未到位不做 headline
family substrate inheritance	T3 退化为 lookup	B6 与 whole-family holdout 决定 Claim 2
PLM pretraining contamination	temporal claim 失真	PLM-seen/unseen strata 与措辞限制
fungal multi-domain/long proteins	truncation 与 pooling 错误	window manifest、domain pooling、alignment tests
SAE 自动描述错误	把假设当注释	descriptions 不进入 label table
taxonomy bias	检索优先找近缘物种	order holdout 和跨 taxon retrieval
结构低覆盖/低置信	fusion 实用价值低	missing-mask、pLDDT gate、coverage-adjusted result
24 GB 单卡限制	6B OOM/吞吐低	6B 限 pilot、多 GPU shard、记录 cost
current/legacy 许可混用	发布风险	每个 artifact 固定模型卡/revision/license

13. 分阶段路线图

Phase 0 - 先解除门槛

1. 裁决 36 alias conflicts。
2. 完成 2024 seed identity。
3. 恢复 ESM-2 ceiling probe。
4. 获得 independent boundaries、characterized function labels、clan map。
5. 固定 current/legacy ESMC license/revision snapshots。

Phase 1 - Frozen ESMC

1. 300M fixture smoke。
2. 600M 全层 pooled sweep ; T1 residue sweep 只在边界子集。
3. nested cluster30 selection ; order/temporal/family 作为外层测试。
4. 与 M0 ESM-2 同 head、同 split、同统计比较。

Phase 2 - Heads 与 LoRA

1. frozen linear/MLP/prototype heads。
2. T1 token head、T2 hierarchy/open-set、T3 multi-task function head。
3. 600M LoRA pilot ; 6B 不做 full fine-tuning。

Phase 3 - SAE 与结构增量

1. B8 dense/SAE retrieval benchmark。
2. B2 Foldseek 与 SaProt 对照。
3. pLDDT-gated fusion 和 no-structure degradation。
4. 只对高价值缺失结构运行 ESMFold2。

Phase 4 - Retrospective fam-0 与发布

1. release N -> N+k retrospective benchmark。
2. 选择 novelty score 与候选排序。
3. 输出模型卡、数据卡、license bundle、cost table 和可复现命令。

14. 最终建议

建议继续，但采用窄而可证伪的 ESMC 集成：

- 立即把 current ESMC 600M 加入 frozen layer-sweep 计划，把 300M 定为 smoke，把 6B SAE 定为 B8；不要立即做全库 6B 或 DAPT。
- 把 ESMC 与 ESM-2、MMseqs2、Foldseek、CAALM、SaProt 放在同一 split 下比较；ESMC 的主要价值假设是远缘 domain/function retrieval，而不是高同源 family softmax。
- 保持 structure-selective。只有 sequence-only/SAE 无法解决且有明确候选价值时才预测结构。
- 把 function decoder 是否超过 B6、structure fusion 是否在 <30% identity/clan/fam-0 上超过 sequence-only，作为两条主 claim 的停止条件。
- 先解决数据门槛，再扩大 GPU 使用。当前最有价值的下一步仍是 alias adjudication + complete seed identity，而不是训练更大的模型。

15. 主要来源

ESMC 一手资料

1. Candido S. et al. Language Modeling Materializes a World Model of Protein Biology. bioRxiv, 2026. DOI: [10.64898/2026.06.03.729735](https://doi.org/10.64898/2026.06.03.729735). 本地审阅 PDF：[/Users/xinpengzhang/Downloads/2026.06.03.729735v1.full.pdf](#)。
2. [Biohub/esm official repository](#) - current code, weights, SAE/ESMFold2 usage and license statement。
3. [ESMC model page](#) - current version、intended use、MIT statement 和模型限制。
4. [Biohub tutorials](#)。具体 notebooks：[embedding](#)、[layer sweep](#)、[LoRA](#)、[mutation scoring](#)、[SAE interpretation](#)、[ESMFold2](#)。
5. [Biohub model limitations](#) - 输出为 computational predictions，underrepresented lineages、short/disordered proteins 可靠性可能变化。

CAZyme 项目与基线

6. [fungi-cazyme-PLM repository](#) 及仓库内 promoted Phase 0 artifacts。
7. Zheng J. et al. [dbCAN3: automated carbohydrate-active enzyme and substrate annotation](#). Nucleic Acids Research, 2023。
8. [CAZyLingua article](#) - sequence-only protein language model CAZyme classification comparator。
9. [CAALM module documentation](#) - hierarchical PLM/FAISS family annotation comparator。

Codex/Cursor 远端工作

10. [OpenAI Codex IDE extension](#) - VS Code-compatible editors , 包括 Cursor。
11. [OpenAI Codex CLI](#) - 从项目目录运行 Codex 与 `codex exec` 自动化 workflow。